#### DATOVÉ STRUKTURY – STROMY



Kurz: Datové struktury a algoritmy / Teoretická informatika

Lektor: Doc. Ing. Radim Burget, Ph.D.

**Autor:** Doc. Ing. Radim Burget, Ph.D.





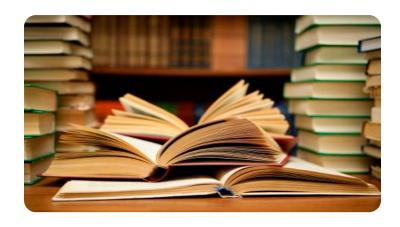






## Cíl přednášky

- 1. Stromová struktura dat
- 2. Stromy a příbuzné datové struktury
- 3. Implementace stromů
- 4. Procházení stromy
- 5. Vyvážené stromy



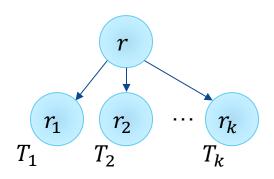
#### Stromová struktura dat

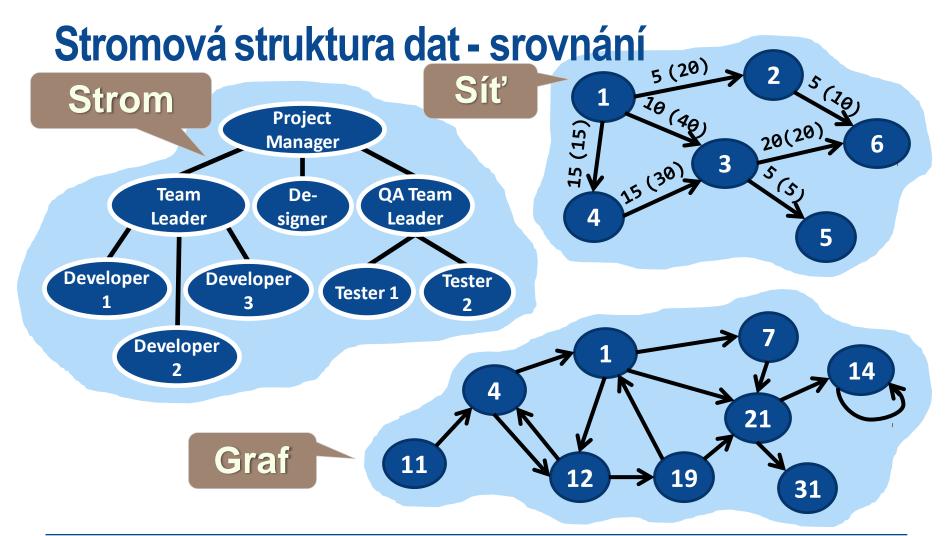
Stromy a vyvážené stromy



#### Stromová struktura dat

- Stromy prostředek pro reprezentaci informace
- Definice:
  - Strom T je konečná množina nula nebo více prvků (uzlů), z nichž jeden je označen jako kořen r (root) a zbývající uzly jsou rozděleny do  $k \ge 0$  disjunktních podmnožin  $T_1, T_2, ..., T_k$ , které jsou také stromy a jejichž kořeny  $r_1, r_2, ..., r_k$  jsou následníky kořene r





#### Stromy – příklady použití

- Jedna z nejčastějších datových struktur
- jeden z možných způsobů indexování klíčů v databázích (systémech řízení báze dat)
- reprezentace znalostí, stavového prostoru v umělé inteligenci
- metody distribuce klíčů v kryptografii (broadcast encryption)
- jakékoli řazené struktury, množiny, atp.
- popis scény v oblasti zpracování a analýza obrazu, počítačová grafika
- vyhledávací stromy v databázových systémech
- rozhodovací stromy expertní systémy
- organizace adresářů a souborů v souborovém systému OS,
- komprese dat (Hufmannovy kódovací stromy, fraktálová komprese)
- atd.

#### Stromová struktura dat

- Stromové struktury jsou speciálním případem graf.
- Významné vlastnosti:
  - Neobsahují cykly
  - Pokud jsou vyvážené a seřazené => velice efektivní pro reprezentaci množin, vyhledávání prvků a řazení prvků

#### Stromy – rozdělení

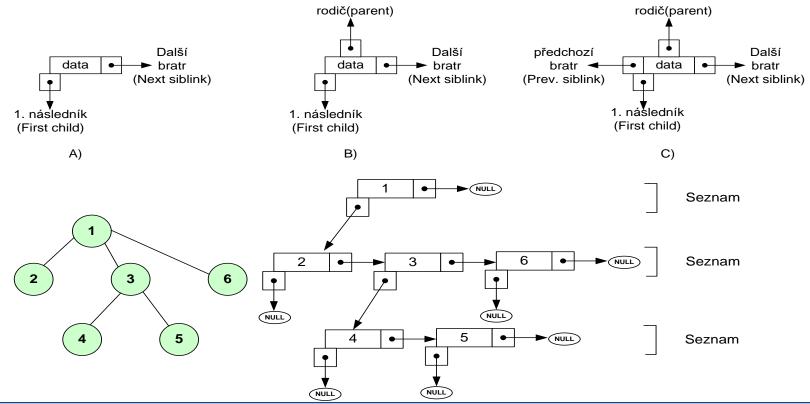
- Obecný strom
- N-ární strom

Vícecesté stromy (Multiway trees)

- Binární stromy
- Binární vyhledávací stromy
  - AVL stromy
  - Red-black stromy
- R stromy (prostorové vyhledávání)

#### Obecný strom

Každý uzel libovolný počet potomků



- getData(): vrací data na této pozici.
- Obecné metody:
  - integer getSize()
  - boolean isEmpty()
  - Iterator iterator()
  - Iterable positions()
- Přístupové metody:
  - Node getRoot()
  - Node getThisParent(p)
  - Node children(p)

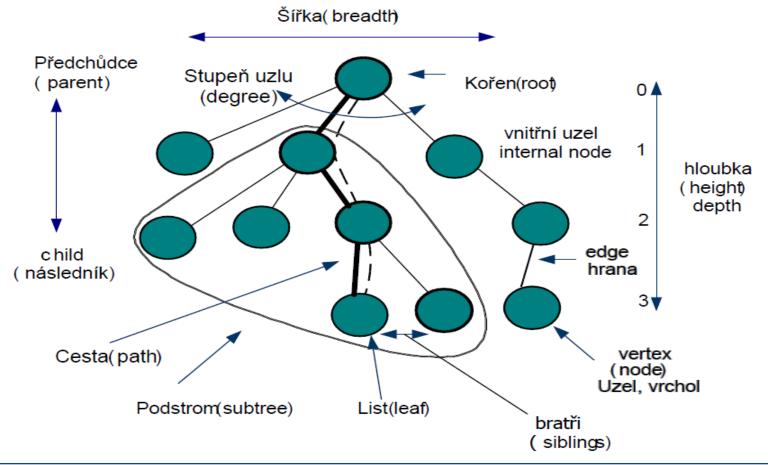
#### Dotazovací metody:

boolean isInternal(p)
boolean isLeaf(p)
boolean isRoot(p)

#### Aktualizační metoda:

element replace (p, o)

#### Stromy a terminologie



#### Hloubka vrcholu

- Nechť v uzlem stromu T. Hloubka vrcholu v je počet předků v (s výjimkou v sebe sama)
  - Pokud v je prázdný (null), potom hloubka v je 0
  - Pokud v je kořen, potom hloubka v je 1
  - V opačném případě se hloubka v je hloubka rodiče v + 1.

```
Algorithm depth(T, v):

if kořen je prázdný T then

return 0

else if v je kořenem T then

return 1

else

return 1+depth(T, w), kde w je rodičem v ve
```

```
Algorithm depth(T, v):
```

```
depth \leftarrow 0

while v != null

v = v.parent

depth \leftarrow depth + 1

return depth
```

(Paměťově efektivnější)

- Časová složitost depth(T, v) je O(d<sub>v</sub>),
  - kde d<sub>v</sub> značí hloubku uzlu v ve stromě T.

stromu T

#### Velikost stromu – rekurzivní varianta

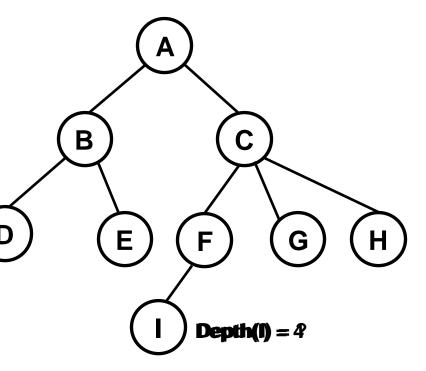
```
Algorithm size (Node root):
{
    if(root!=NULL)
        return(1 + size(root->child1)
        + size(root->child2) + ... + size(root->childn));
    else return 0;
}
```

#### Výška stromu

 Hloubka vrcholu: počet předků(včetně sebe).

 Výška stromu: maximální hloubka externího uzlu stromu / podstromu.

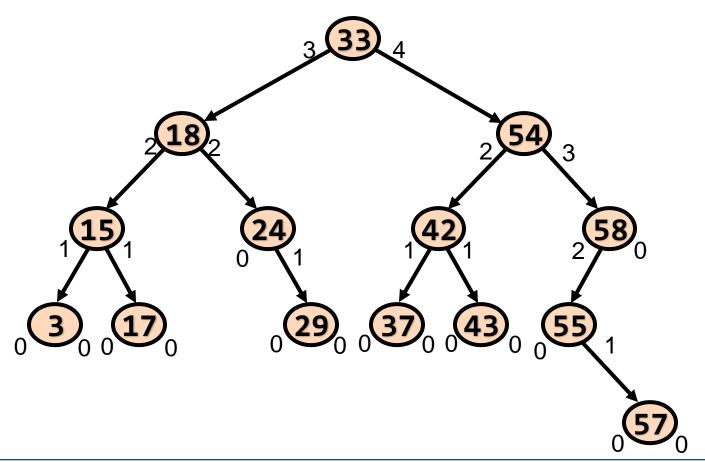
 Pokud neobsahuje žádný vrchol, tak je 0
 Depth(D) = 3



Height = MAX[ Depth(A), Depth(B), Depth(C), Depth(D), Depth(E), Depth(F), Depth(G), Depth(H), Depth(I) ]

Height = MAX[ 1, 2, 2, 3, 3, 3, 3, 3, 4 ] = 4

## Příklad: Určete výšku podstromů



Výška uzlu v ve stromě T může být určena jako:

```
Algoritmus height1(T):

h \leftarrow 0

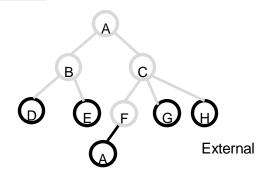
for each vertex v in T do

if v is an external node in T then

h \leftarrow \max(h, \operatorname{depth}(T, v))

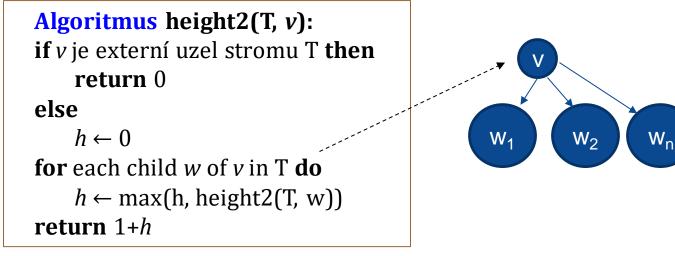
return h
```

Algoritmus height1 má časovou složitost O(n²)



#### Výška stromu – efektivní přístup

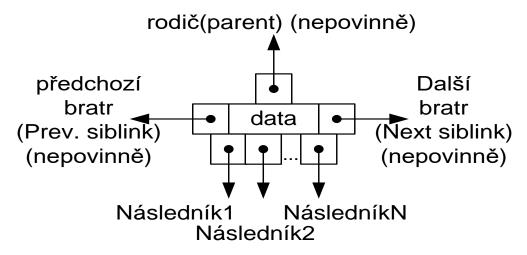
- Výška uzlu v ve stromu T je rekurzivně definována:
  - Pokud v je listem, potom výška v je 1
  - V opačném případě v je jedna plus maximální výška potomka w.



algoritmus height2 má časovou složitost O(n)

#### N-ární stromy

- maximálně N potomků
- N je konstanta
- Omezenější nežli obecný strom



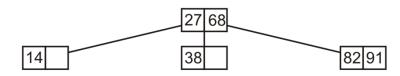
#### Ternární stromy

 Switche některých výrobců přepínaných síťových prvků akcelerují směrovací tabulky pomocí ternárních TCAM tabulek (až 10x zrychlení)



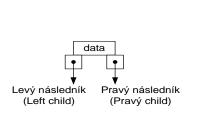
TCAM (Ternary Content Addressable Memory)

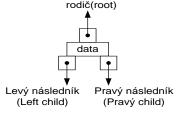
Klasický princip je binární:

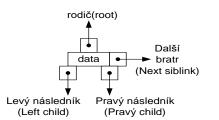


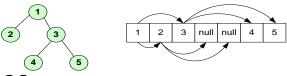
# Binární stromy

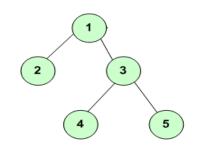
- N-ární strom, kde N = 2
- Většina stromových struktur použitých v informatice jsou binární stromy
- Prvky nejsou seřazeny
- Implementace má několik variant (záleží na způsobu použití)
  - Ovlivňuje schopnost se pohybovat v stromové struktuře (výkon)
  - Zvyšuje nároky na paměť

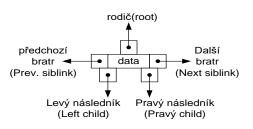






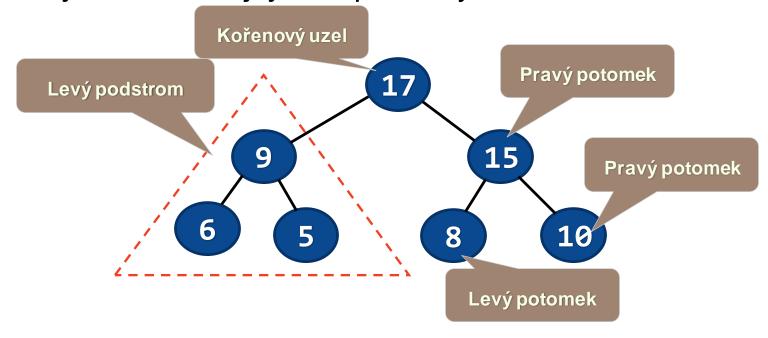






## Binární stromy

- Binární stromy: speciální terminologie
  - Každý uzel má nejvýše 2 potomky

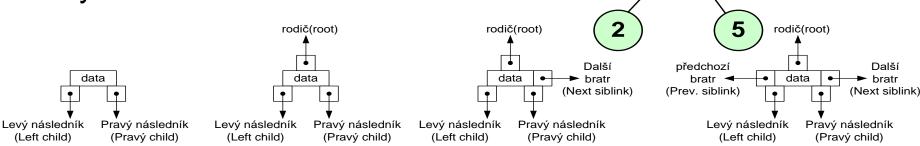


- Binární vyhledávací stromy jsou řazené
  - Pro každý uzel x ve stromě platí:
    - Všechny uzly v levém podstromu uzlu x jsou ≤ x
    - Všechny uzly v pravém podstromu uzlu x jsou > x
- Binární stromy mohou být vyvážené
  - Vyvážené stromy mají hloubku ~ log<sub>2</sub>(x)
  - Vyvážené stromy mají pro každý uzel téměř stejný počet uzlů v jejich podstromech

 (Definice) Binární vyhledávací stromy jsou stromy, kde musí pro každý uzel platit, že hodnota všech potomků z levého podstromu je menší než hodnota rodiče, a hodnota všech potomků z pravého podstromu je větší než hodnota rodiče.

Tj. Prvky jsou seřazeny

Vychází z binárního stromu

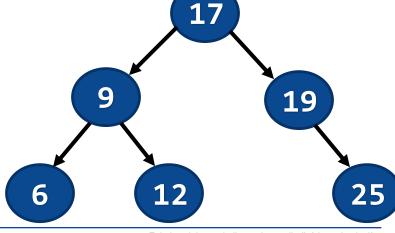


-2

3

- Příklad vyváženého binárního vyhledávacího stromu
- Příklad: Vložte do prázdného stromu prvky 17, 9, 6, 12, 19, 25
- Pozn: Co se stane pokud vložím prvky v pořadí 6, 9, 12, 17, 19, 25 ? Jaký to bude mít dopad na vyhledání

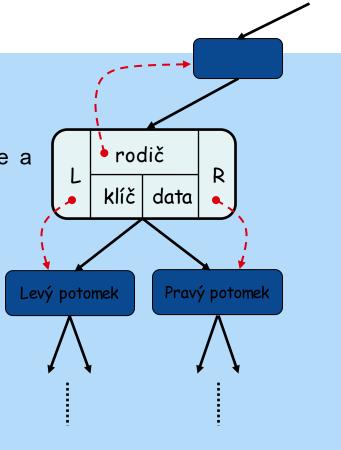
libovolného prvku (výkon)?



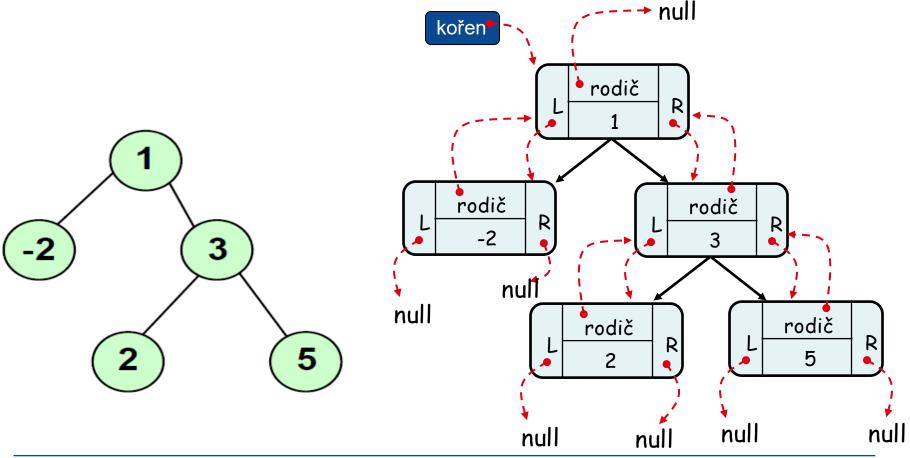
#### Binární vyhledávací stromy - implementace

# Node - parent: Node - leftChild: Node - rightChild: Node - dataValue: int Metody get & set BinaryTree - root: Node + insertNode(int value) + removeNode(int value) + findNode(int value): boolean

- Reprezentace stromových struktur:
  - Provázaná datová struktura
  - Rozšiřujeme často o klíč + hodnota (pro jednoduchost toto rozdělení zanedbáváme a budeme předpokládat, že klíč = data)
- Příklad implementujte:
  - Key atribut
  - Data
  - · Left: ukazatel na levý podstrom
  - Right: ukazatel na pravý podstrom
  - p: ukazatel na rodiče(p [root [T]] = NIL)



#### Binární vyhledávací stromy – implementace



#### Vyhledávání v BVS

- Provyhledání hodnoty k, prohledáváme BVS odspodu nahoru, kde začínáme v kořenu.
- Další navštívený uzel závisí na hodnotě k a hodonty aktuálního uzlu.
- Pokud soáhneme listu, hodnota neexistuje.
- Příklad: contains(4):

```
Rekurzivní varianta:

Algoritmus TreeSearch(k, v)

if T.isExternal (v)

return v

if k < key(v)

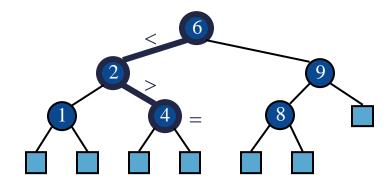
return TreeSearch(k, T.left(v))

else if k = key(v)

return v

else { k > key(v) }

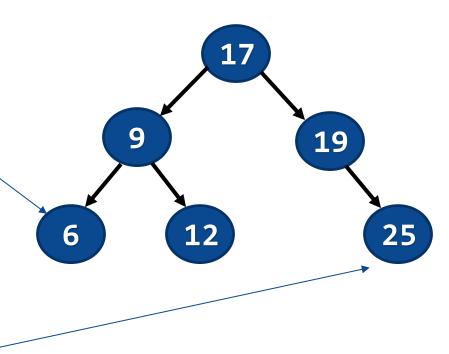
return TreeSearch(k, T.right(v))
```



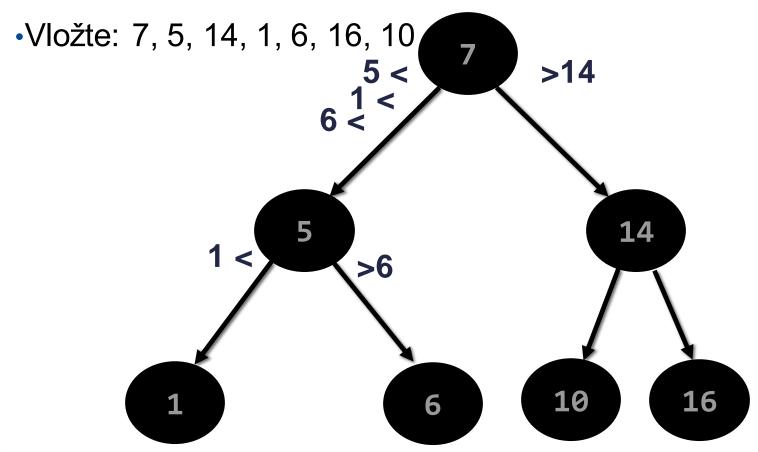
#### Nalezení minima / maxima (rekurzivní varianta)

```
NalezniMinimum (T)
{
    if (t_left is not empty)
        return NalezniMinimum(levý podstrom);
    else
        return key(t);
}
```

```
NalezniMaximum (T)
{
    if (t_right is not empty)
       return NalezniMaximum(pravý podstrom);
    else
       return key(t);
}
```



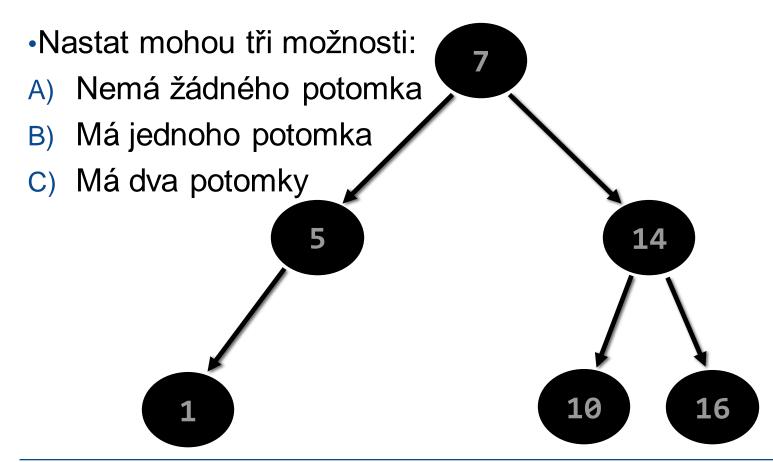
#### Vložení prvku do prázdného BVS



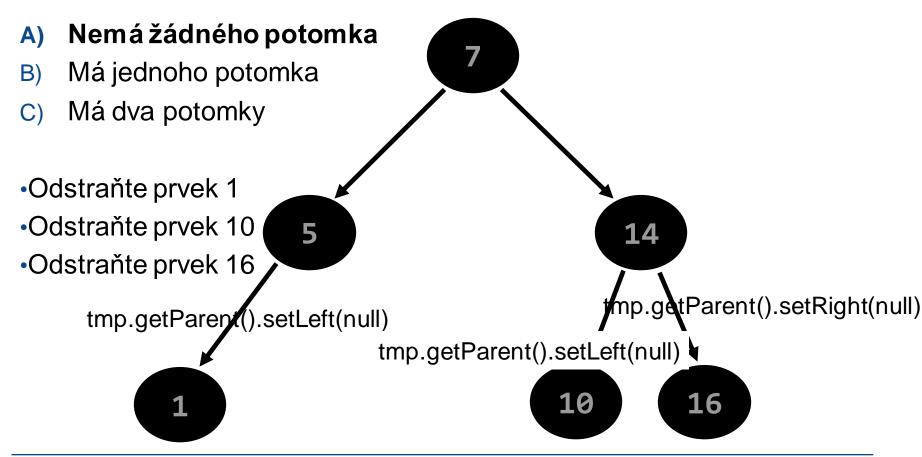
#### Algoritmus vložení: rekurzivní varianta

```
Insert (tree, new_item)
if (tree je prázdný)
    vlož na kořen;
else if (shoduje se s aktuálním uzlem)
    nedělej nic; (duplicitní klíč)
else if (nový klíč je menší než aktuální kořen)
    volej rekurzivně insert na levý pod-strom;
else
    volej rekurzivně insert na pravý pod-strom
```

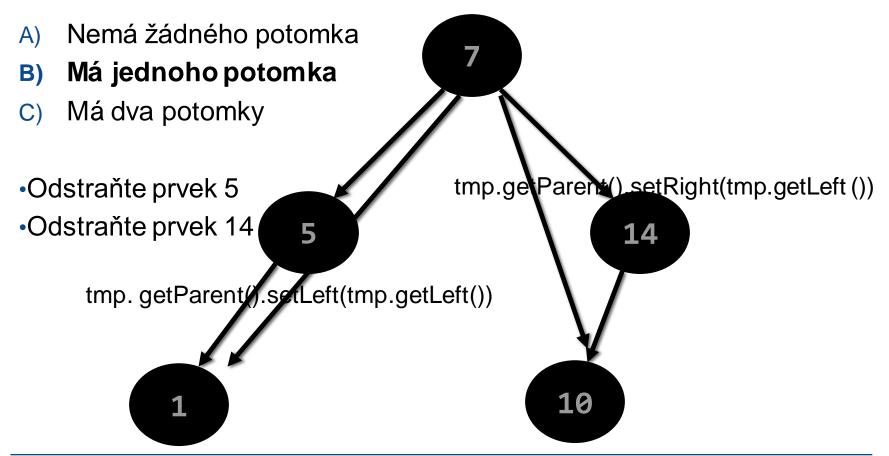
#### Odstranění prvku



# A) Odstranění prvku – nemá žádného potomka?



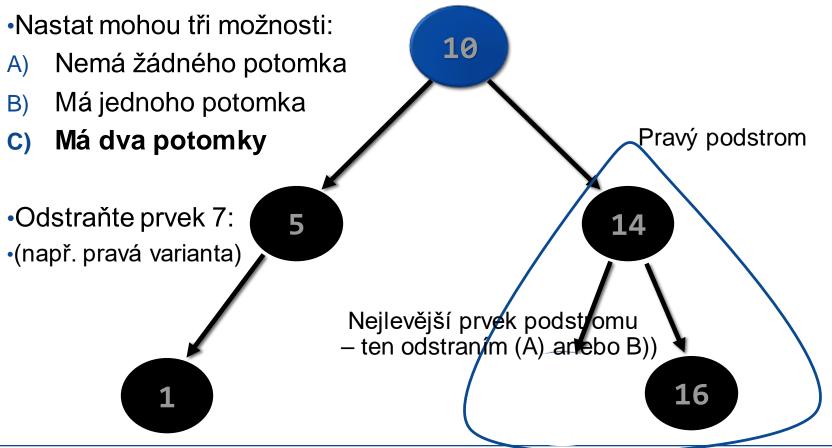
# B) Odstranění prvku – má jednoho potomka



#### C) Odstranění prvku – má oba potomky

- A) Nemá žádného potomka
- B) Má jednoho potomka
- C) Má dva potomky
  - Její součástí jsou kroky A anebo B tzn. podařilo se vám porozumět krokům A) a B)?
  - Existují 2 varianty levá a pravá

## C) Odstranění prvku – má oba potomky









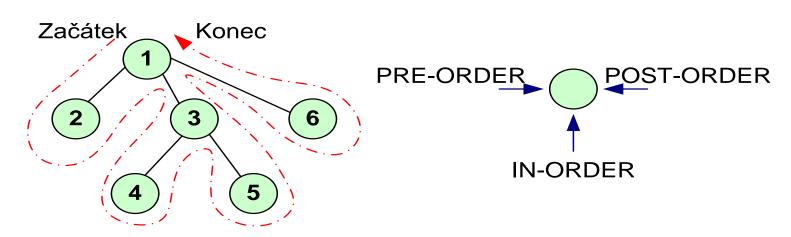
### Algoritmy pro procházení stromů

• Pre-order: 1 2 3 4 5 6

• In-order: 2 1 4 3 5 6

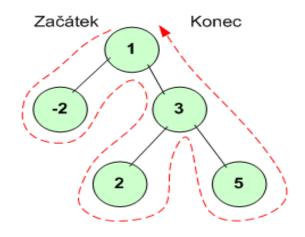
• Post-order: 2 4 5 3 6 1

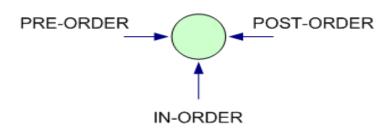
+ revresní varianty (zleva doprava)



# Algoritmy pro procházení stromů

 Jeli strom binární vyhledávací -> metoda in-order vrací prvky ve správném pořadí: -2 1 2 3 5





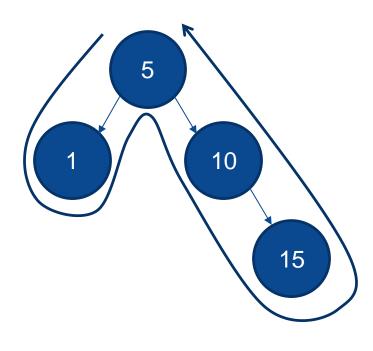
```
public class Spustitelna {
    public static void main(String[] args) {
        MujStrom s = new MujStrom();
        s.pridej(5);
        s.pridej(10);
        s.pridej(1);
        s.pridej(15);

        s.vypis();
    }
}
```

```
public void vypis() {
    vypis(koren);
}

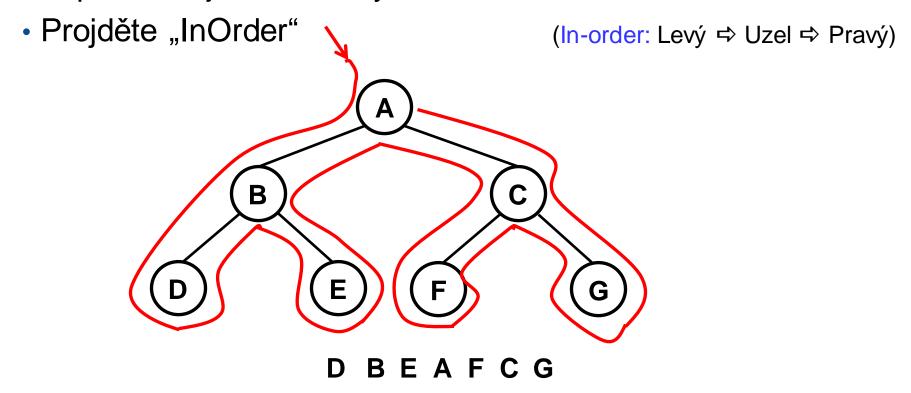
private void vypis(Uzel u) {
    if(u == null) {
        return;
    }
    vypis(u.getLevy());
    System.out.println(u.getData());
    vypis(u.getPravy());
}
```

**IN-ORDER** 



#### Příklad: Průchod stromem In-order

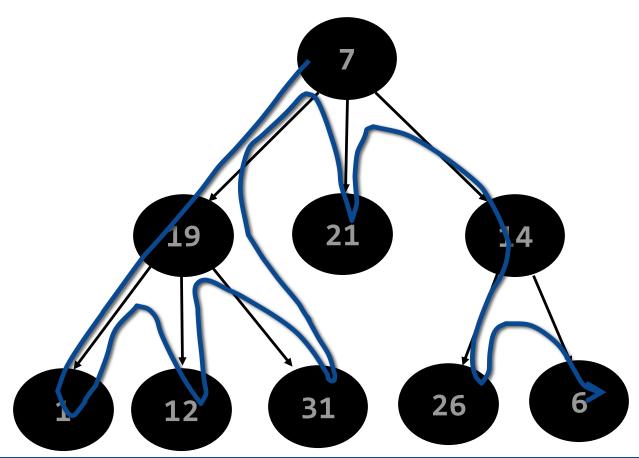
Implementujte binární vyhledávací strom



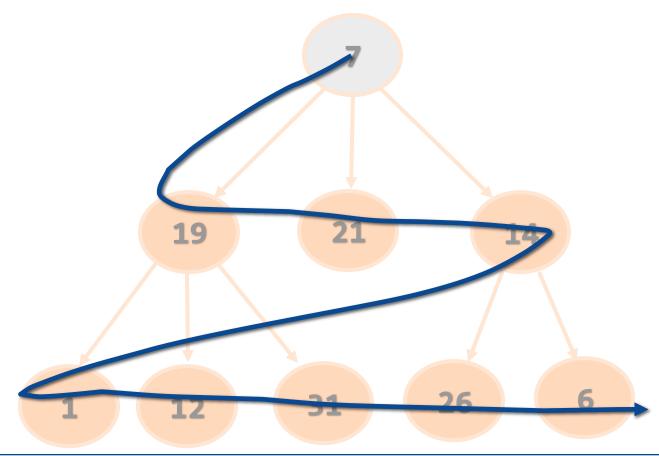
# Algoritmy pro procházení stromů

- Stromy jsou speciálním případem grafu a lze tedy na nich aplikovat veškeré algoritmy pro procházení/vyhledávání v grafech:
  - Prohledávání do hloubky DFS (Depth-First Search)
    - Nejdříve se projde celá větev
  - Prohledávání do šířky BFS (Breadth-First Search)
    - Nejdříve se prochází všichni potomci zkoumaného uzlu
  - Algoritmům procházení grafem se budeme věnovat detailněji později

# Prohledávání do hloubky – DFS (Úvod)



# Prohledávání do šířky – BFS (Úvod)



# Vyvážené vyhledávací stromy

• AVL stromy, Red-Black stromy, (také B-stromy, B+-stromy, 2-3 stromy, 2-3-4 stromy, AA-stromy, (a, b) stromy, B-stromy, ...)

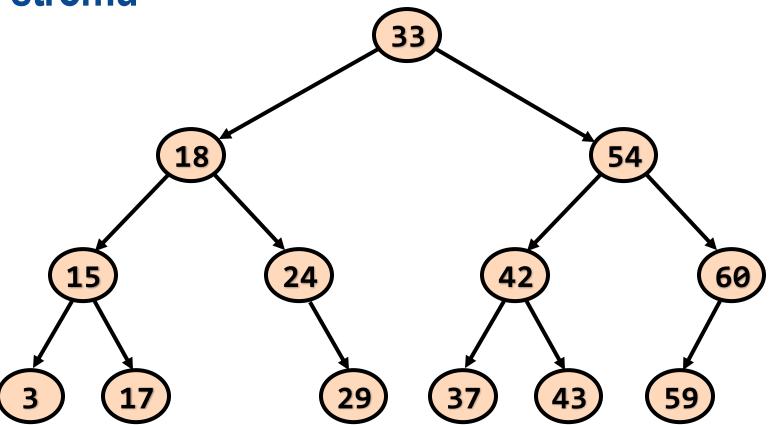




# Vyvážený binární vyhledávací strom

- Vyhledávací binární strom
  - Pro každý uzel x ve stromě platí:
    - Všechny uzly v levém podstromu uzlu x jsou ≤ x
    - Všechny uzly v pravém podstromu uzlu x jsou > x
- Vyvážený strom
  - Rozdíl hloubky levého a pravého podstromu každého uzlu je vždy nula nebo jedna.
- Vyvážený binární vyhledávací strom
  - má výšku log<sub>2</sub>(n) kde n je počet uzlů
  - Vyhledávání ve stromě tedy znamená přibližně log<sub>2</sub>(n) operací

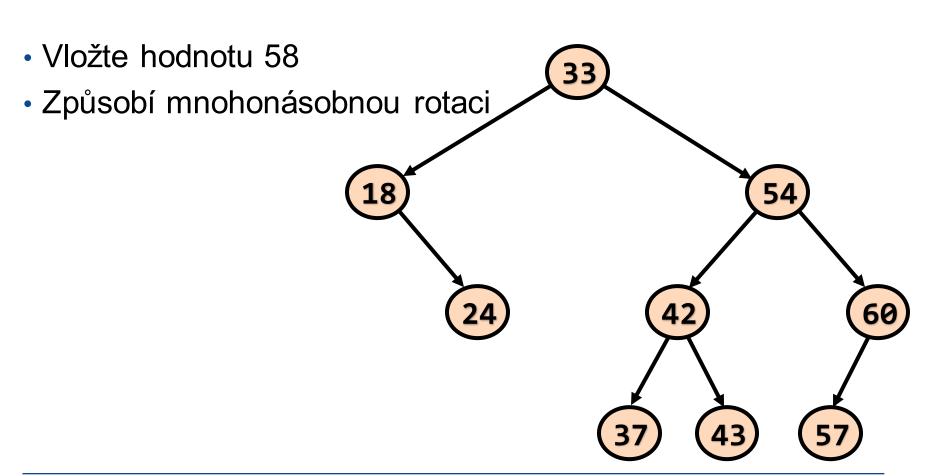
# Příklad vyváženého vyhledávacího binárního stromu



# Vyvážený binární vyhledávací strom

- Vyvažování po vkládání a mazání je komplexní operace
- Příklady implementace vyvážených binárních vyhledávacích stromů:
  - AVL stromy lépe vyvážené, hrozí problém mnohonásobné rotace
    - Efektivnější vyhledávání, méně efektivní vkládání
  - Red-black stromy zhruba vyvážené, řeší problém mnohonásobné rotace
    - Efektivnější vkládání, méně efektivní vyhledávání

#### Mnohonásobná rotace

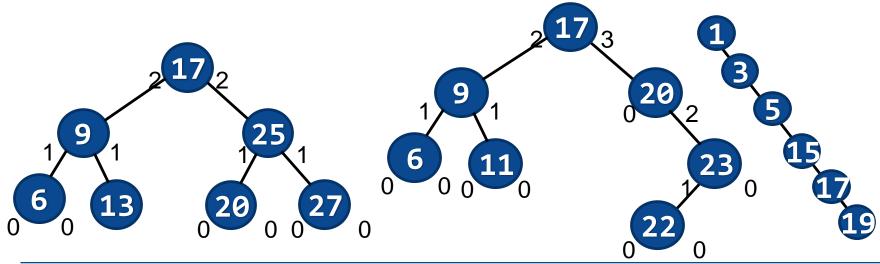


# AVL stromy a vkládání

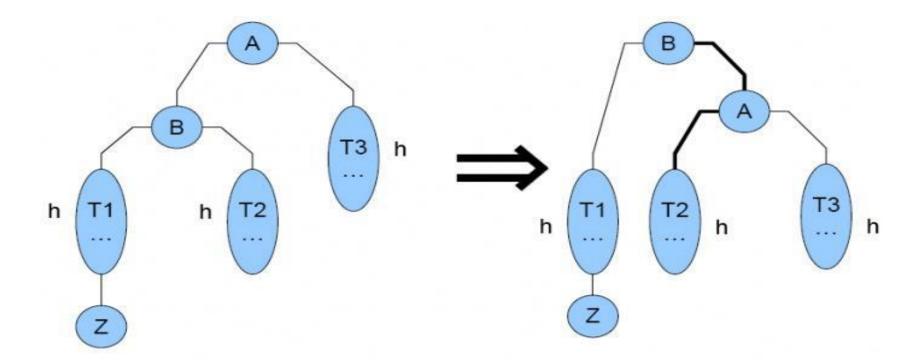
- Vkládání má dvě fáze:
  - Vložení jako u vyhledávacího stromu
  - Následuje kontrola vyváženosti
    - Pokud není strom vyvážený, provede se některá rotace

# Vyvážené binární stromy

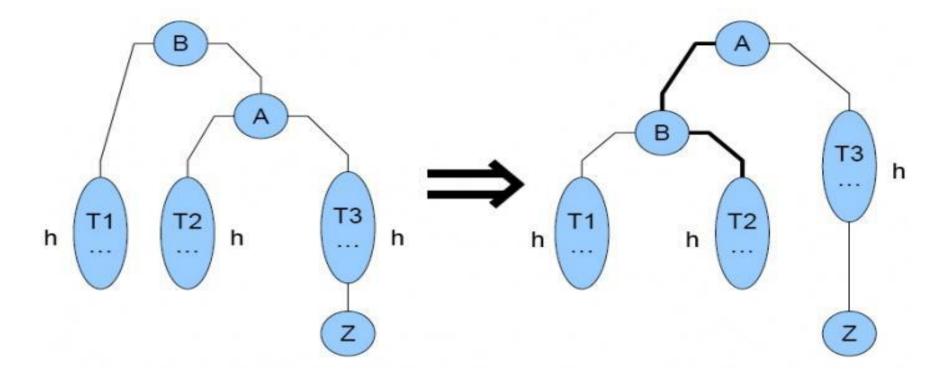
- Binární strom označíme za dokonale vyvážený, jestliže pro jeho libovolný vrchol v platí, že počet vrcholů v levém a pravém podstromu vrcholu se liší nejvýše o 1.
- Strom je vyvážený, právě když se <u>hloubky obou podstromů</u> každého uzlu připojených k jeho libovolnému vrcholu, liší nejvýše o 1.



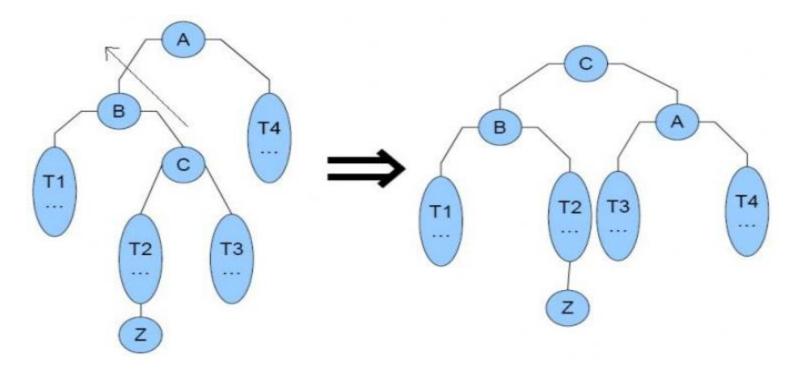
Jednoduchá levá rotace – SLR (Single Left Rotation)



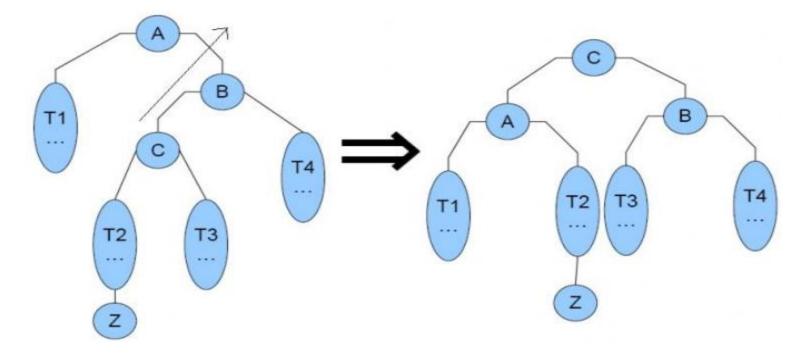
Jednoduchá pravá rotace – SRR (Single Right Rotation)



Dvojnásobná levá rotace – DLR (Double Left Rotation)

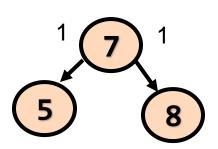


Dvojnásobná pravá rotace – DRR (Double Right Rotation)

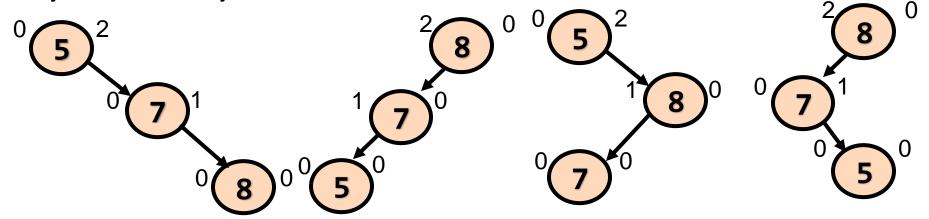


## Mějme 5, 7, 8 v BVS? Jak mohou vypadat?

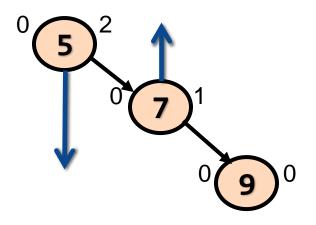
Vyvážená varianta:

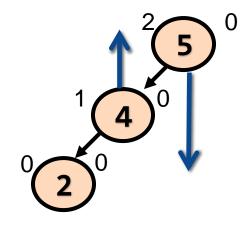


Nevyvážené varianty:

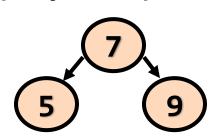


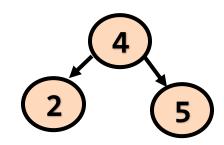
### Jednoduché příklady – varianta do / anebo \



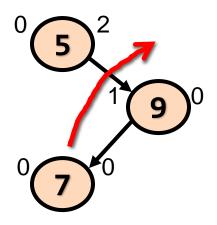


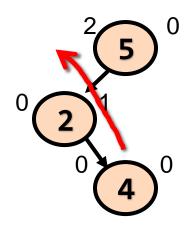
Výsledek po vyvážení pomocí AVL:



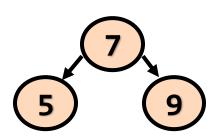


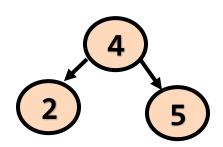
#### Jednoduché příklady – varianta do < anebo >



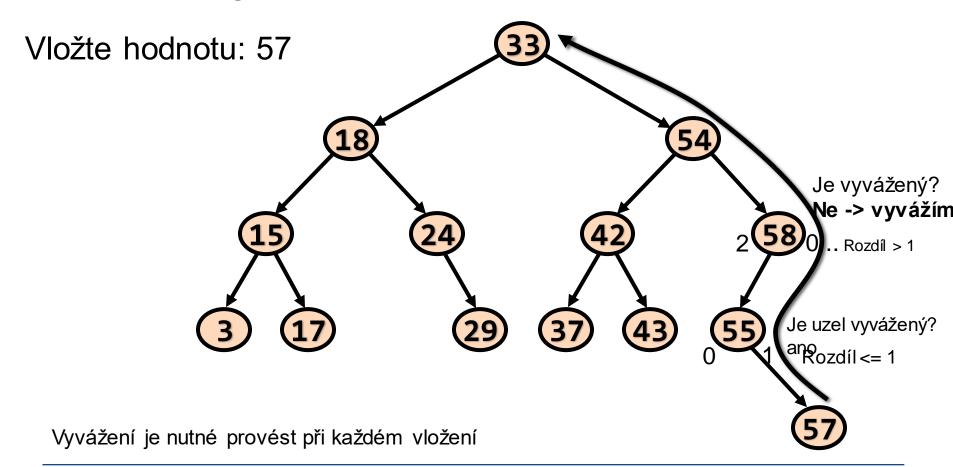


Výsledek po vyvážení pomocí AVL:

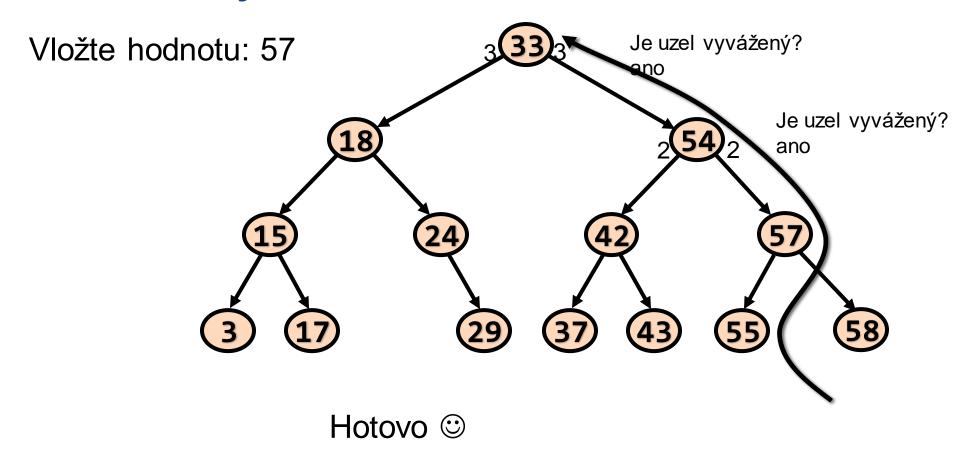




# Kontrola vyváženosti



# Kontrola vyváženosti



# Příklad: Vyvažování stromů

- Vložte prvky do prázdného vyhledávacího stromu (vyvažovaného algoritmem AVL) v tomto pořadí:
- Jednoduché příklady:
  - 4, 6, 8
  - 7, 4, 1
  - 5, 3, 4
  - 6, 9, 8

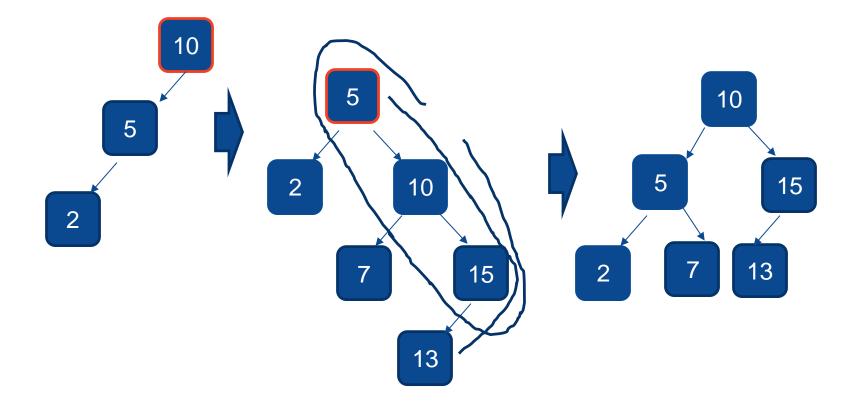
#### Pokročilejší příklady:

- 5, 3, 8, 10, 12
- 7, 4, 8, 10, 13
- 8, 3, 10, 5, 4, 7

#### Extrémní příklad:

• 52, 8, 2, 11, 18, 36, 39, 38, 28, 71, 61, 66, 67, 58, 75, 87, 72, 95

# Vložte: 10, 5, 2



# Jednoduché příklady

• 4, 6, 8; **7, 4, 1**; 5, 3, 4; **6, 9, 8** 

# Pokročilejší příklady

• 5, 3, 8, 10, 12; **7, 4, 8, 10, 13**; 8, 3, 10, 5, 4, 7

# Pokročilejší příklad

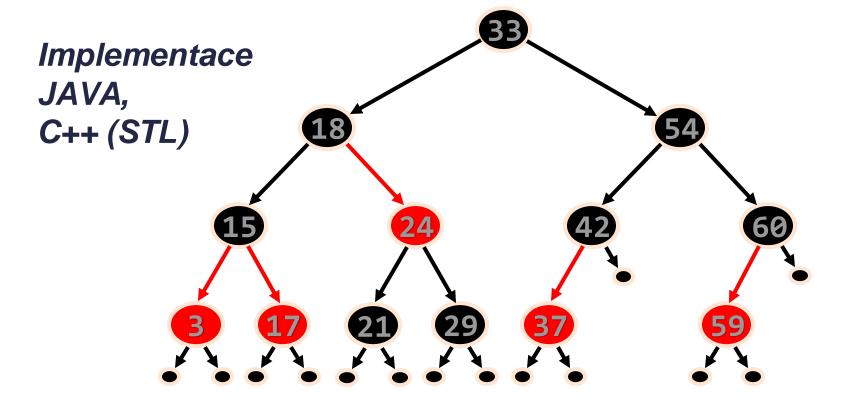
52, 8, 2, 11, 18, 36, 39, 38, 28, 71, 61, 66, 67, 58, 75, 87, 72, 95

## **Red-Black stromy**

Pro Red-Black stromy platí tato pravidla:

- Každý uzel je vždy červený nebo černý
- Kořen stromu je černý
- Všechny listy jsou černé
- · Oba potomci červeného uzlu jsou černé
- Každá cesta z libovolného uzlu do jeho podřízených listů obsahuje stejný počet černých uzlů

#### Red – Black stromy – ukázka



#### Red - Black stromy

#### Odkazy na příklady

Red-Black stromy nebudou součástí příkladu v rámci zkoušky (je ale nutné vědět co to je).

#### Více informací:

- Animace binárních vyhledávacích stromů
- · Vkládání do Red Black stromu nejhorší případ
- Zdrojové kódy Red Black stromu v Javě a mnoho dalších

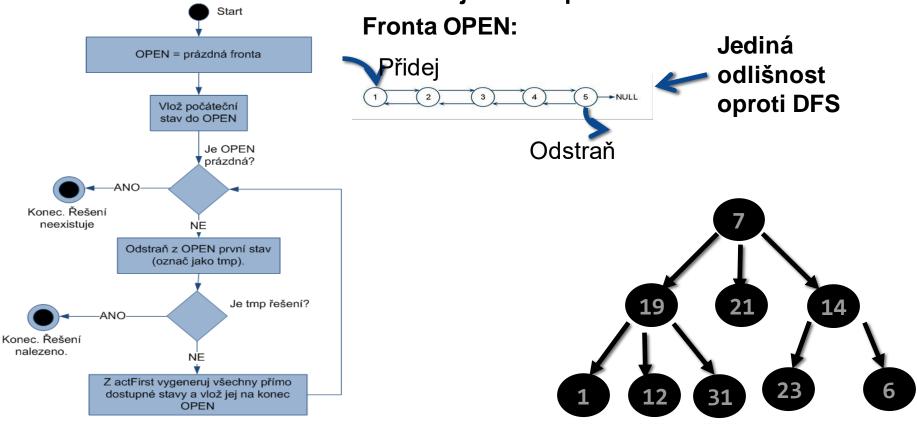
# Prohledávání do šířky - algoritmus

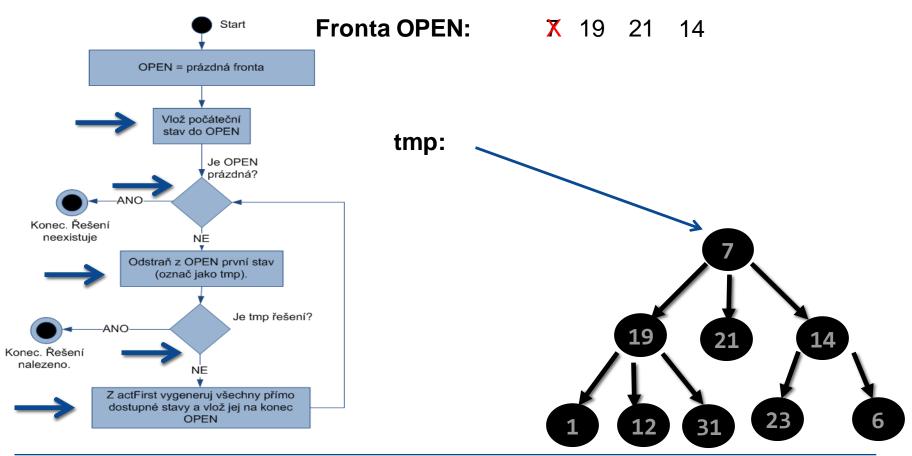




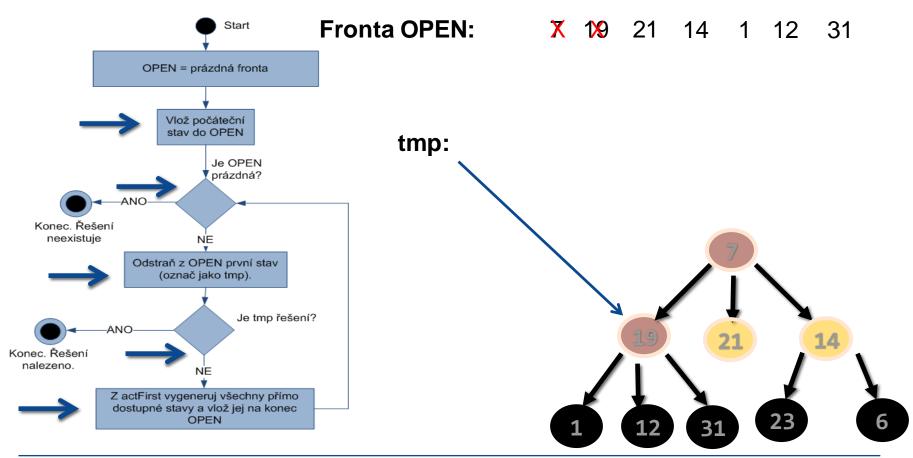
## Prohledávání do šířky – BFS – Implementace

Jak se dostanu ze stavu 7 do stavu 6 s nejmenším počtem tahů?

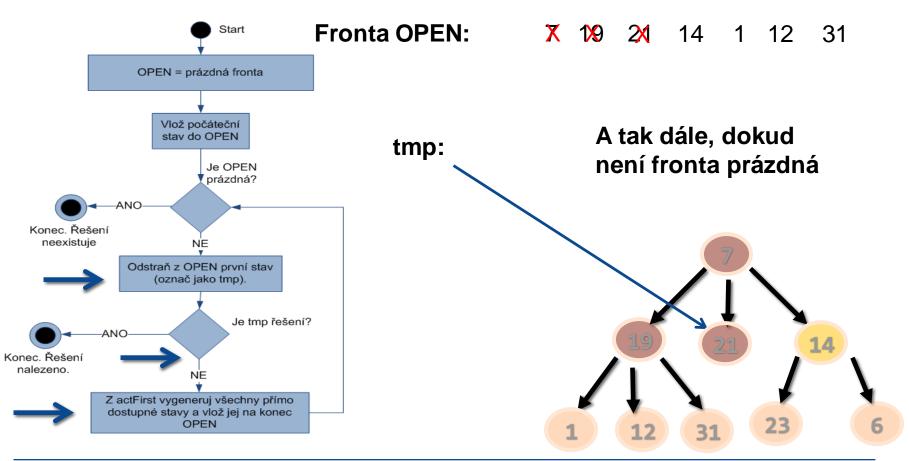




# Prohledávání do šířky – BFS - Implementace



#### Prohledávání do šířky – BFS - Implementace



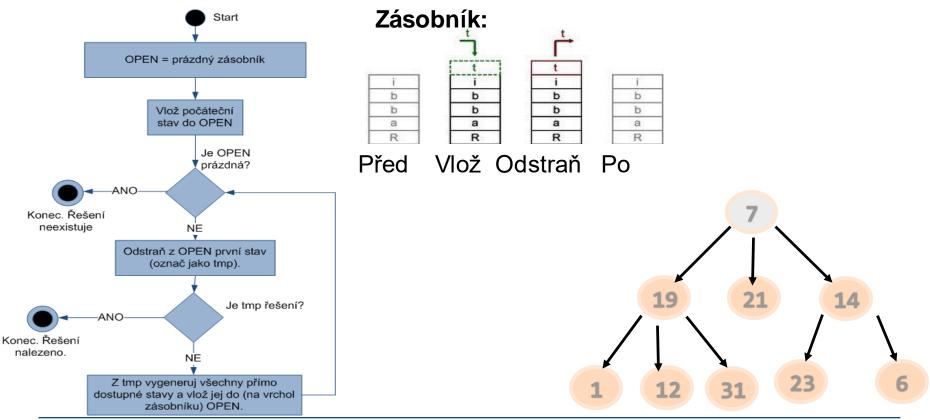
#### Prohledávání do hloubky - algoritmus



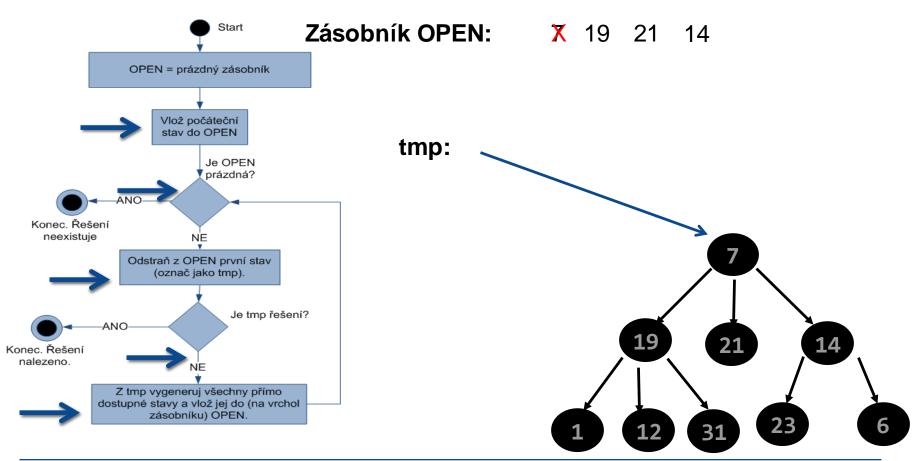


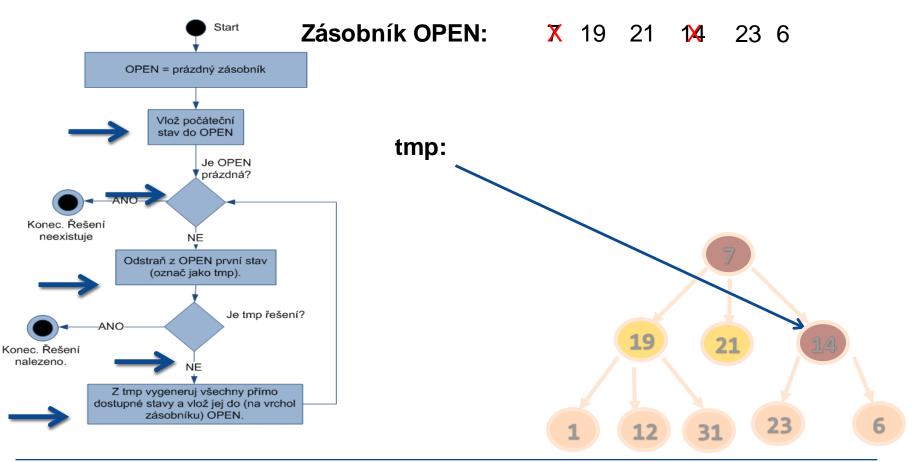
## Prohledávání do hloubky – DFS - Implementace

Jak se dostanu ze stavu 7 do stavu 6 (existuje taková cesta) ?

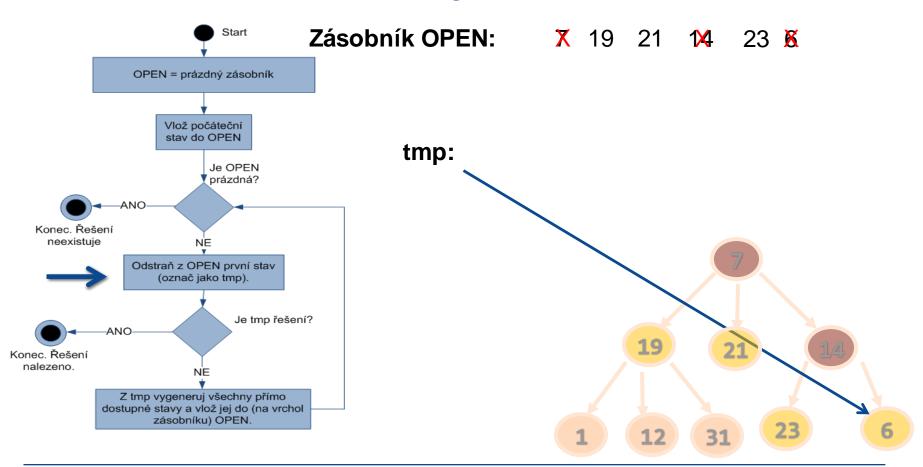


#### Prohledávání do hloubky – DFS - Implementace





#### Prohledávání do hloubky – DFS - Implementace



## Binární vyhledávací strom - shrnutí

Operace nad BVS:

SEARCH

• MINIMUM	O(h)	
<ul> <li>MAXIMUM</li> </ul>	O(h)	h výška stromu
• INSERT	O(h)	$h = log_2(n)$

O(h)

• DELETE O(h)

• BFS O(v+e) V ... počet vrcholů

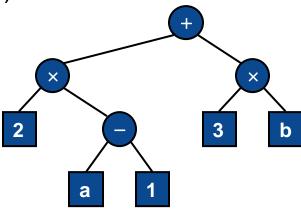
• DFS O(v+e) e ... počet hran

Výška náhodně postaveného binárního vyhledávacího stromu na n různých klíčích je O(2 log<sub>2</sub> n)

## Aritmetický výrazový strom

- Binární strom asociovaný s aritmetickým výrazem:
  - · Interní uzly: operátory
  - Externí uzly: operandy
- Příklad: Aritmetický výrazový strom pro výraz

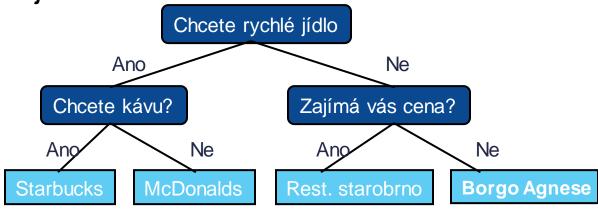
$$(2 \times (a - 1) + (3 \times b))$$



#### Rozhodovací stromy

- Binární rozhodovací strom asociovaný s rozhodovacím procesem
  - Vnitřní uzly: otázka s odpovědí ano/ne
  - Listy: rozhodnutí

Příklad: rozhodnutí o jídle

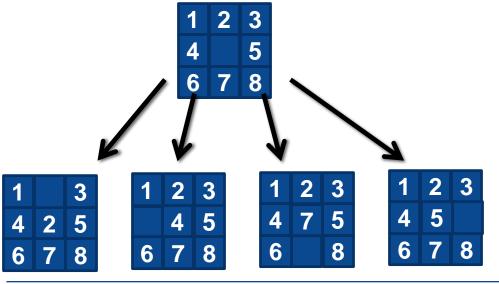


#### Huffmanovo kódování

- Huffmanovo kódování je technika pro bezeztrátovou kompresi dat.
- Konvertuje znaky vstupního souboru do bitových řetězců různé délky.

#### Význam prohledávání stromů

- Přestože byl algoritmus představen z pohledu teorie, má mnoho praktických využití – zejména v kombinaci s grafy (budeme se jimi zabývat později)
- Mnoho problémů lze převést do podoby stromové struktury









představen

#### Příklad I.

- Pracujeme na projektu pro analýzu sémantického obsahu textových dokumentů. Vytvořme filtr, který získá seznam vyskytujících se slov v seřazeném pořadí.
- Analyzovat se budou miliony dokumentů
- Lineární struktury (lineární složitost odstrašující případ)
- Hash výkonnostně dobré, neřadí
- TreeSet správná volba



#### Příklad II.

- V rámci Real-time protokolu chodí každou sekundu přibližně 50 paketů. Jelikož jsou pakety přenášeny skrze UDP protokol, je potřeba zajistit: řazení, eliminaci duplicit
- Možnosti:
- Pole anebo seznamy (vyhledávání či řazení časově náročné)
- HashSet (výkonostně dobré, neřadí prvky)
- TreeSet (správná volba)



#### **Shrnutí**

- · Obecný, n-ární, binární
- Vyhledávací
- Vyvážený

#### strom

- Operace nad stromy:
  - Vkládání, odstranění, vyhledávání
- Průchody:
  - In-order, pre-order, post-order
  - DFS
  - BFS (po úrovních)
- Vyvažování:
  - AVL vyvažování
  - V praxi se používá: Red-Black strom (vědět, že existuje + umět srovnat, nebude předmětem zkoušení)

## K zamyšlení

**1 4** = **8** 

- Proč nastává ClassCastException?
  - = nemohu přetypovat na třídu java.lang.Comparable
  - A jak ji opravit?

```
public class Car {
    public int vin;
}
```

(Vehicle Identification Number)

```
TreeSet<Car> mySet = new TreeSet<>();
mySet.add(new Car());
```

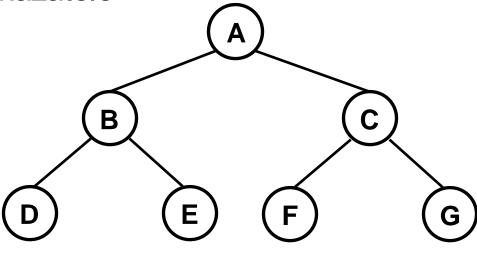
```
Exception in thread "main" <a href="mainto:java.lang.ClassCastException">java.lang.Comparable</a> at java.util.TreeMap.compare(Unknown Source) at java.util.TreeMap.put(Unknown Source) at java.util.TreeSet.add(Unknown Source) at java.util.TreeSet.add(Unknown Source) at cz.vutbr.feec.dsa.Runnable.main(<a href="mainto:Runnable.java:8">Runnable.java:8</a>)
```

#### Děkuji za pozornost



 Převeďte binární vyhledávací strom na seřazený obousměrně vázaný seznam. Nesmí být vytvářena nová paměť, pouze lze měnit ukazatele

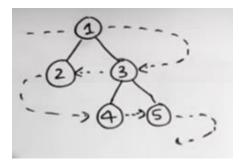




DBEAFCG



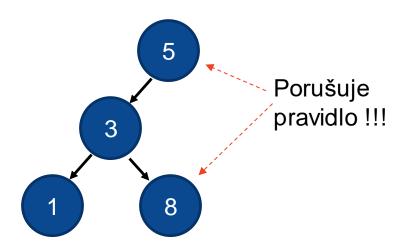
- Nalezněte nejhlubší uzel v binárním stromu.
- Napište funkci, která rozhodne, zdali je binární strom vyvážený.
- Nalezněte všechny uzly ve vzdálenosti k od kořene.
- Zig-zag průchod stromem



- · Ze seřazeného pole vytvořte binární vyhledávací strom
- Ověřte, že všechny listy stromu jsou stejné úrovně



- Napište funkci k určení, zda daný binární strom (odlišná celá čísla) je platný binární vyhledávací strom.
  - Složitější problém
    - Přímá rekurze nefunguje.





- Napište funkci pro průchod binárním vyhledávacím stromem
  - bez rekurze / zásobníku / paměti navíc.
  - Tip můžete rozšířit strukturu dat uzlu. Do uzlu však nemůžete přidat navštívené pole.

Vytiskněte strom jako:

(Rodič (leftchild (leftchild, rightchild), rightchild (leftchild, rightchild)))

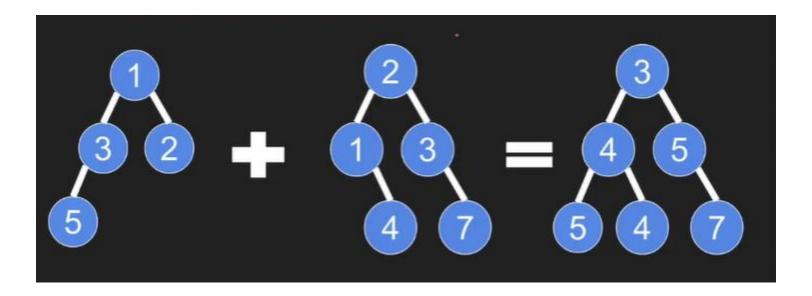


- Napište kód pro Huffmanovo kódování
- Pozn: Hufmanovo kódování je stromová struktura

Char	četnost	
E	125	
Т	125 93	
Α	80	
О І	76	
I	76 73	
N	71	
N S R H	65	
R	61	
Н	55	
L	41	
D	40	
C U	31	
U	40 31 27	



Slučte 2 stromy tak, aby vznikl binární vyhledávací strom

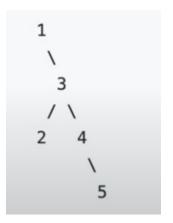






 Najděte nejdelší po sobě jdoucí sekvenci v binárním rozhodovacím stromě.

#### Příklad



Nejdelší je 3, 4, 5 odpověď je tedy 3.

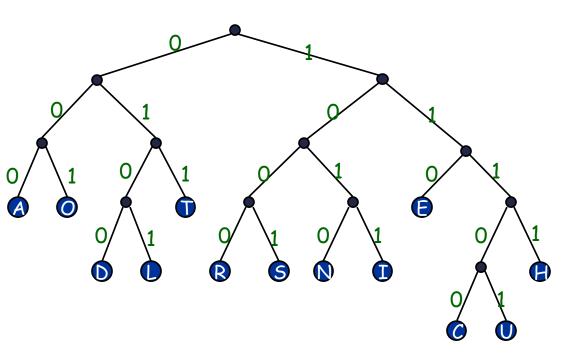
- Nalezněte nejbližšího společného předchůdce v binárním stromu
  - Určete vzdálenost mezi dvěma uzly v binárním stromu (obecném, nejen vyhledávacím)
- Rozhodněte, zdali dva binární stromy jsou identické, či nikoli

#### Rovnost dvou stromů

- Navrhněte algoritmus, který ověří, že dva binární stromy jsou identické.
- Nelze alokovat novou paměť, pouze jednorozměrné pomocné reference.

# Řešení: Otázka z přijímacího pohovoru





Char	Freq	Fixed	Huff
Е	125	0000	110
Т	93	0001	011
Α	80	0010	000
0	76	0011	001
I	73	0100	1011
Ν	71	0101	1010
5	65	0110	1001
R	61	0111	1000
Н	55	1000	1111
L	41	1001	0101
D	40	1010	0100
С	31	1011	11100
U	27	1100	11101
Total	838	4.00	3.62